基于卷积神经网络的畸变星座图调制模式识别报告

一、 实验目的与任务背景

调制模式识别在无线电频谱监测、非合作通信对抗以及信号解调等领域中占有举足轻重的地位。在非合作对抗的复杂电磁环境中，由于多径效应、频偏以及噪声干扰，接收到的射频信号往往会出现严重的时空相位偏置和幅度衰减，导致解析出来的星座图发生不规则的拉伸、平移或旋转畸变。本实验的任务是利用机器学习方法构建一个信号调制模式分类器，要求在不同信噪比（SNR）环境及通道畸变干扰下，对输入的 6 种常见调制模式（包括 BPSK、QPSK、8PSK、PAM4、QAM16 和 QAM64）进行精准辨识。

二、 星座图数据集介绍与预处理

本实验所使用的数据集由 6 种信号调制模式的星座图图像构成，每种调制类别的子文件夹中均包含 500 张在不同信噪比下生成的 640x480 分辨率的 RGBA 彩色图像。为了控制网络参数规模、降低计算负荷并提高模型的训练速度，我们设计了如下预处理流程：

1. 通道降维：将原始 RGBA 四通道彩色星座图降维为单通道灰度图，仅保留星座点分布的亮度和密度空间信息。

2. 图像重采样：使用双线性插值算法将图像分辨率缩放为 64x64 像素。

3. 归一化处理：将像素值缩放至 [0, 1] 范围，并采用均值为 0.5、标准差为 0.5 的参数进行标准化（Normalize），使网络输入数据具有零均值、相同方差 of 优良分布特性，有利于网络权重的快速收敛。

三、 卷积神经网络（CNN）模型架构

星座图的模式分类本质上属于空间分布特征提取与识别问题。我们搭建了一个轻量高效的二维卷积神经网络，其主要结构如下：

1. 卷积层 1：采用 1 通道输入、16 通道输出，卷积核大小为 3x3，使用 ReLU 激活函数。随后接入 2x2 最大池化层，将特征图尺寸减半（变为 32x32）。

2. 卷积层 2：使用 32 个 3x3 卷积核进行高阶特征提取，ReLU 激活。配合 2x2 最大池化后，特征图尺寸变为 16x16。

3. 卷积层 3：使用 64 个 3x3 卷积核进行更深层次的空间语义特征映射，ReLU 激活。第三次池化后，输出 8x8 特征图。

4. 全连接层与分类器：首先将 64x8x8=4096 维特征展平，经过一个包含 128 个神经元的隐藏层（ReLU 激活），并引入 30% 概率的 Dropout 以防止模型对训练集过拟合，最后通过输出层映射为 6 个调制类别的得分向量。

四、 模型训练与实验结果分析

本实验将 3000 张星座图样本按照 8:2 的比例随机划分为训练集（2400 张）与测试集（600 张）。训练超参数设置为：使用 Adam 优化器，初始学习率设为 0.001，批大小（Batch Size）为 64，共迭代训练 8 个 Epoch。损失函数采用交叉熵损失（Cross-Entropy Loss）。在 CPU 硬件平台上训练得到的损失收敛曲线和测试

准确率变化曲线如下图所示：

图 1 信号调制分类网络训练 Loss 与测试 Accuracy 收敛曲线

实验结果显示：在首个 Epoch，模型对畸变星座图的测试分类准确率即达到了 58.33%。随着训练的进行，训练损失稳定下降，测试准确率稳步爬升。在第 6 个 Epoch 准确率达到 79.83%，并最终在第 8 个 Epoch 达到了 80.83% 的测试识别准确率。

结合信号星座图特点分析可知：QAM64 和 QAM16 在低信噪比下，星座点会因噪声扩散而严重混叠，形状难以分辨，这是限制模型准确率进一步提升的主要瓶颈。而 BPSK、PAM4 和 QPSK 等低阶调制由于欧氏距离大，抗畸变能力强，在模型中具有极高的分类召回率。

五、 结论

本实验基于 PyTorch 框架构建的 CNN 信号调制分类模型，能够有效地从带有频偏和相位畸变的二维星座图中提取高阶空间拓扑分布特征。在仅经过 8 个 Epoch 迭代训练的条件下，取得了 80.83% 的识别准确率，验证了卷积神经网络在处理射频信号星座图分类任务上的卓越泛化能力和稳健性。