基于多层感知机神经网络的锂电池健康状态（SOH）预测报告

一、 实验目的与任务背景

锂离子电池由于能量密度高、寿命长、无记忆效应等优点，已成为移动电子设备和电动汽车的绝对核心储能单元。然而，随着充放电循环的增加，电极材料老化和电解液消耗会导致电池容量渐进式衰减。准确地估计锂电池的健康状态（State of Health, SOH）对保障系统的运行安全、合理规避热失控风险具有极其关键的作用。由于电池内部电化学劣化机制极度复杂，SOH 无法直接在线测量，只能通过外部可测量物理量间接估计。本实验通过机器学习方法，利用从电池充放电电压、电流中提取的间接健康因子特征，构建数据驱动的 SOH 神经网络回归预测模型。

二、 特征工程与数据加载

实验采用来自 CALCE 的电池循环衰减测试数据集。本研究使用 `openpyxl` 批量解析了包含 CS2 电池（标称容量 1100mAh）与 CX2 电池（标称容量 1350mAh）在内的 8 组完整的寿命测试 Excel 报表。

基于电池充电曲线的物理机理，模型选取了以下 4 维核心健康特征因子：

1. 恒流充电时长 (cc_duration)：指电池在充电第一阶段进行恒流充电所持续的时间。电池老化后，内阻增大，恒流阶段会更早结束。

2. 恒压充电时长 (cv_duration)：恒流充电结束后进入恒压充电阶段的持续时间，反映极化效应。

3. 充电时间间隔 (timeInterval)：指每次完整充电循环的总耗时。

4. 增量容量曲线峰值 (ica_max)：微分容量曲线 (dQ/dV) 上的主峰最大值，反映活性电极材料的容量退化状态。

模型的预测目标标签（Label）为电池健康状态 SOH（定义为当前循环最大容量与标称容量的比值）。我们从训练集中计算特征的极大、极小值，并应用 Min-Max 归一化将输入特征缩放到 [0, 1] 区间，以消除各物理量纲差异对网络梯度下降造成的不利影响。

三、 多层感知机 (MLP) 回归模型设计

考虑到电池特征维数较低（4 维），且特征与 SOH 之间呈现高度非线性映射关系，我们搭建了一个深层的全连接前馈神经网络（Multi-Layer Perceptron）：

- 输入层：接收 4 个特征节点；
- 隐藏层 1：64 个神经元，使用 ReLU 激活函数进行非线性特征组合；
- 隐藏层 2：32 个神经元，激活函数为 ReLU；
- 隐藏层 3：16 个神经元，激活函数为 ReLU；
- 输出层：1 个神经元，线性输出 SOH 的预测值。

模型使用均方误差（MSE Loss）作为损失函数，利用 Adam 优化器，学习率设为 0.005，通过对所有数据进行 2000 个 Epoch 的训练以确保权重收敛。

四、 实验结果与评估分析

为严格检验模型的跨电池泛化能力，我们采用极其严苛的测试机制：将 CS2_33 至 CS2_38 以及 CX2_34 电池的所有循环数据（共 7117 个样本）作为模型训练集；而将完全未参与过训练的另一只独立电池 CX2_36 的全寿命周期数据（共 1913 个样本）作为测试集，用来验证模型对未知电池衰减曲线的预测精度。

模型在测试电池 CX2_36 上的最终预测表现指标如下表所示：

- 均方误差 (MSE)：0.000453
- 平均绝对误差 (MAE)：0.009470
- 决定系数 (R2 Score)：0.9768

实际 SOH 曲线与我们训练的 MLP 模型预测得到的 SOH 拟合衰减轨迹对比图如下图所示：

图 2 测试电池 CX2_36 实际 SOH 与神经网络回归预测 SOH 对比衰减曲线

从拟合曲线及指标可见：模型在未知的独立测试电池上表现出了极佳的拟合度和跟踪精度。R2 决定系数高达 0.9768，表明神经网络捕捉到了高达 97.68% 的电池容量演化特征；平均绝对百分比误差小于 1%，且成功拟合了电池在寿命后期衰减速率加快的非线性趋势。

五、 结论

本实验表明，采用恒流充电时间、恒压充电时间等 4 个易于从车载 BMS 系统中获取 of 间接参数作为健康因子，并结合三层 MLP 神经网络，能够高精度地在线监测和预测锂电池的健康状态（SOH）。决定系数 R2 达到 0.9768，验证了该方案在实际电池管理系统应用中的高精度与强跨电池泛化表现。