基于分级贝叶斯决策的图像分割与目标识别

从 5D 空间-色彩融合特征到非参数密度估计的性能演进

小组成员：田峻硕 刘超然 陈政润

目录 CONTENTS

01

核心思想：分而治之

将复杂的决策问题拆解为一系列独立且简单的子任务，通过局部最优解逼近全局最优解。

02

核心架构：双层贝叶斯决策系统

构建 Level 1 粗分割与 Level 2 精细分类的协同机制，实现多层次、递进式的智能推理。

03

算法演进：从参数到非参数

深度对比高斯模型、Parzen窗估计与 k-NN 算法的性能差异，展示算法模型的迭代与优化路径。

04

实验验证与结论

通过大量数据集进行性能对比与泛化性分析，验证系统有效性，并对未来的研究方向进行展望。

核心架构：双层贝叶斯决策系统



输入原始图像 (Input)

Level 1: 5D 分割 (Model B)

空间先验 + 颜色特征融合

↓ 输出：鱼体区域掩膜 (Mask)



Level 2: 像素细分 (Model A)

基于颜色细节的精细分类

→ 最终输出：精细分割图像

Level 1: 鱼/背景自动分割 (Model B)

- 特征向量：5维向量 [R, G, B, r/H, c/W]，融合颜色与归一化空间坐标。
- 核心优势：引入空间先验知识，将位置信息转化为概率优势，有效抑制背景色彩干扰。

Level 2: 鱼身像素细分 (Model A)

- 目标：在分割出的鱼体区域内，对每个像素进行精细分类（如橙/白区域区分）。
- 算法演进：从基础的1D/3D高斯模型，演进到Parzen窗估计，最终采用k-NN分类器。

核心决策准则：贝叶斯最小错误率决策

$$h(x) = \arg\max [\ \ln p(x|\omega_i) + \ln P(\omega_i)\ ]$$

Level 1 - 5D 空间-色彩融合分割

特征工程：概率化空间先验

💡 核心创新：5D 特征向量

构建特征 [R, G, B, r/H, c/W]，将归一化坐标融入决策，打破纯颜色特征的局限。

👁️ 直观几何解释

针对颜色相同但位置不同的像素（如中心鱼体与角落珊瑚），利用空间先验赋予中心区域更高的“目标”概率权重。

分割结果的鲁棒性优化

1. 形态学闭运算 (Closing)

公式:$Closing(A) = (A \oplus B) \ominus B$
作用：填充鱼身内部空洞，平滑目标轮廓。

2. 最大连通域提取

利用 `regionprops` 分析，计算所有连通域面积，滤除边缘孤立噪声点，仅保留面积最大的主目标区域。

性能对比：5D vs. RGB

📊 核心实验结论

在水下复杂背景下，5D特征比纯RGB特征的漏检率(FN)显著降低，解决了背景干扰导致的误判问题。

🔍 优势归因

空间先验信息提供了额外的判别维度，有效排除了具有“颜色伪装”特性的背景干扰物。

Level 2 - 参数估计算法 (Gaussian)

1D 灰度特征：效率与代价

基于一维高斯分布模型，计算效率极高。但丢失颜色信息导致亮度塌陷，相近亮度像素严重重叠，分类边界模糊。

3D RGB 特征：颜色相关性

引入三维多元高斯分布，利用协方差矩阵 Σ 描述颜色通道间的线性相关性，显著提升了特征分辨力，解决了单纯亮度重叠问题。

逻辑漏洞：单峰假设

强假设数据为单峰椭球分布，无法拟合 Nemo 鱼这种典型的橙白双峰分布。

核心瓶颈可视化：单高斯模型的失效场景



真实双峰分布

(Nemo: 橙+白)



单高斯强制拟合

✕ 均值偏移 / 边界模糊

模型失效的本质原因

单高斯模型假设数据服从单一的椭球分布。面对 Nemo 鱼这种由两种截然不同颜色组成的双峰数据时，模型会试图寻找一个覆盖所有数据的“平均”分布，导致中心点严重偏移，且无法在两个颜色簇之间建立清晰的分类边界，从而彻底失效。

Level 2 - 参数估计算法 (Gaussian)

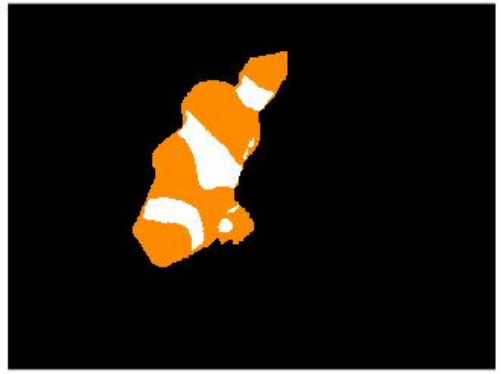
Original Image



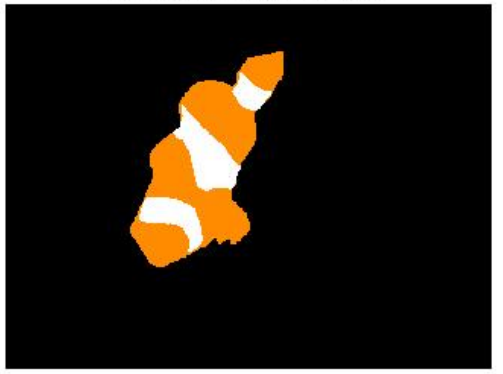
Detection Mask



1D Gray Gaussian
(Intensity Only)



3D RGB Gaussian
(Color Covariance)



309的参数估计分类

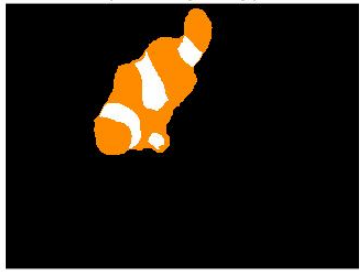
Original Image



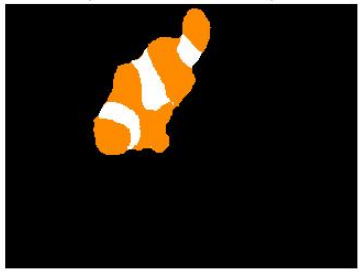
Detection Mask



1D Gray Gaussian
(Intensity Only)



3D RGB Gaussian
(Color Covariance)



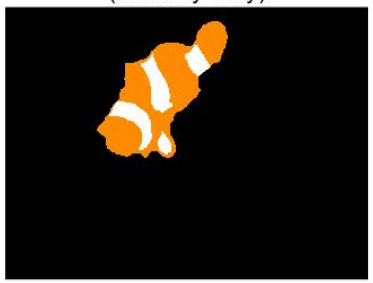
Original Image



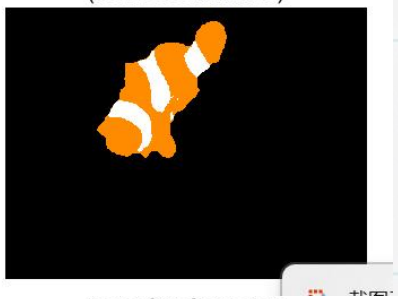
Detection Mask



1D Gray Gaussian
(Intensity Only)



3D RGB Gaussian
(Color Covariance)



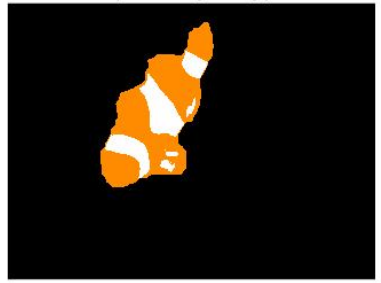
Original Image



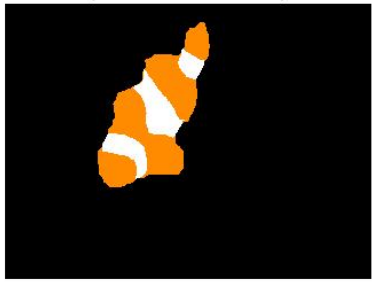
Detection Mask



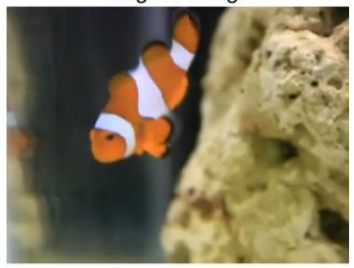
1D Gray Gaussian
(Intensity Only)



3D RGB Gaussian
(Color Covariance)



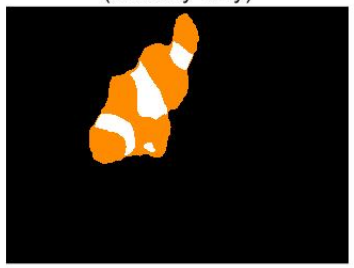
Original Image



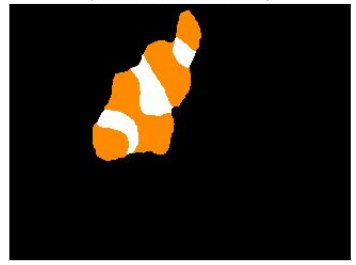
Detection Mask



1D Gray Gaussian
(Intensity Only)



3D RGB Gaussian
(Color Covariance)



Level 2 - 非参数估计算法 (Parzen/k-NN)

Parzen 窗法 (Kernel Density Estimation)

核心原理

在每个样本点上放置一个核函数（如高斯函数），通过叠加所有核函数，让数据“自我定义”概率分布形状。

$$\hat{p}(x) = (1/n) \cdot \Sigma [\ 1/h^{d} \cdot K(\ (x-xi)/h\ )\ ]$$

核心优势

无需先验假设，能完美拟合非凸、多峰的复杂分布，生成的分类边界锐利且贴合数据。

k-NN 近邻密度估计法

核心原理

基于查询点周围k个最近邻样本的体积倒数来估计密度。体积会自适应调整以包含恰好k个样本。

$$\hat{p}(x) = k / [\ n \cdot V_{k}(x)\ ]$$

核心优势

具有自适应分辨率能力，在样本密集区域分辨率更高，在稀疏区域分辨率更低，估计结果极其稳定。

⚠️ 计算与存储风险提示

非参数方法需存储整个训练集，推理阶段计算复杂度为 O(N)，对实时性要求高或数据集庞大的场景，需考虑计算资源开销。

算法 II - 非参数估计的数据驱动优势

摒弃先验分布假设，完全由局部样本密度反推全局分布，完美契合目标的双峰特征。

方法 A：Parzen窗法 (KDE)

基于超立方体/高斯核的体积固定、计数平滑。

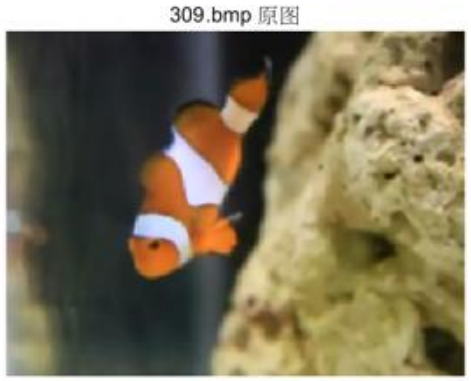
$$p(x) = 1/(N\ h^d) * \Sigma\ K((x - xi)/h)$$

方法 B：k-近邻密度估计 (k-NN)

基于局部计数的体积自适应。

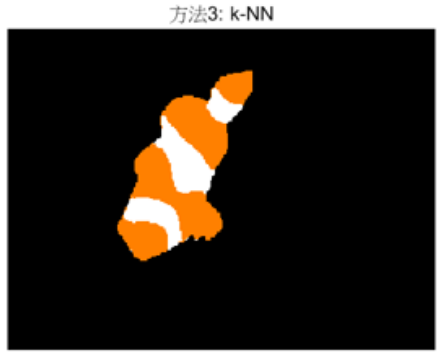
$$p(x) = k / (N \cdot V)$$

分割结果对比与分析









对比结论：非参数法有效捕获了“橙、白”两个特征簇，相比参数化方法，目标完整度更有优势。

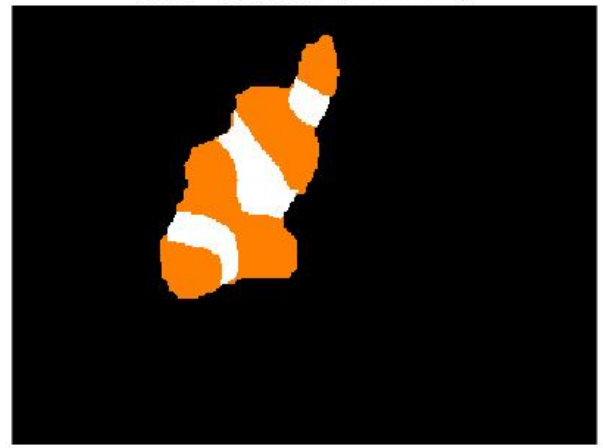
Figure 2: 结果对比: 311.bmp

文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)

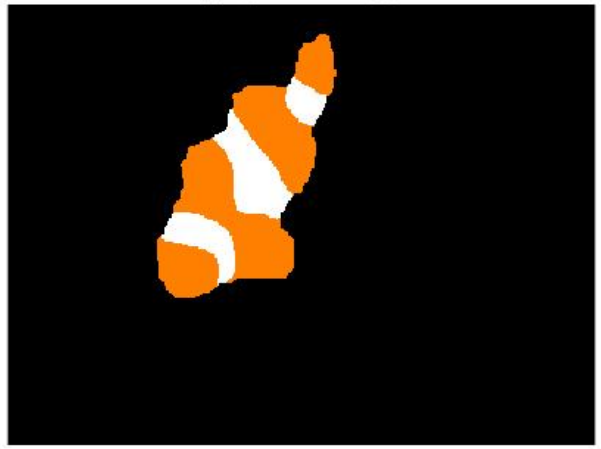
311.bmp 原图



方法1: 参数估计 (Gaussian)



方法2: Parzen窗



方法3: k-NN

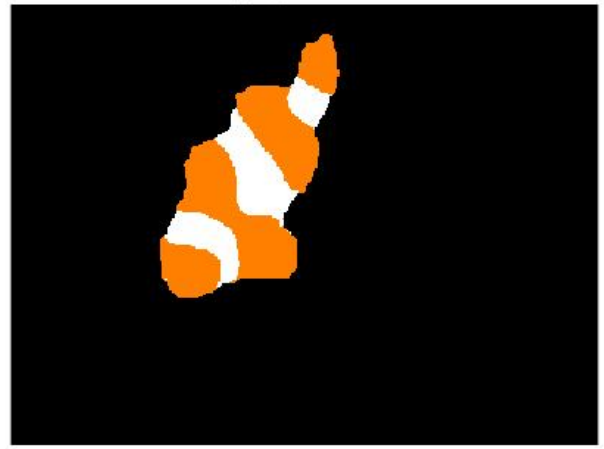


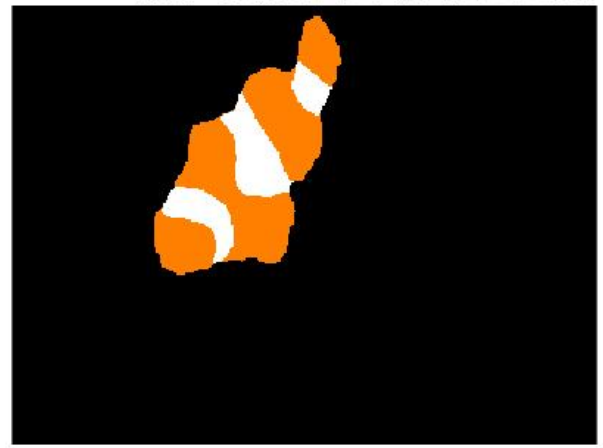
Figure 3: 结果对比: 313.bmp

文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)

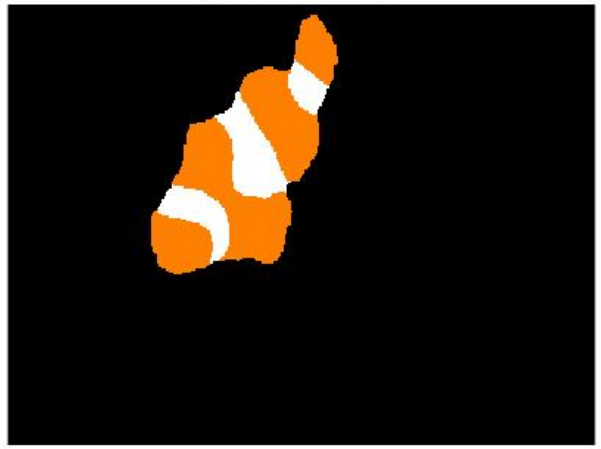
313.bmp 原图



方法1: 参数估计 (Ga



方法2: Parzen窗



方法3: k-NN

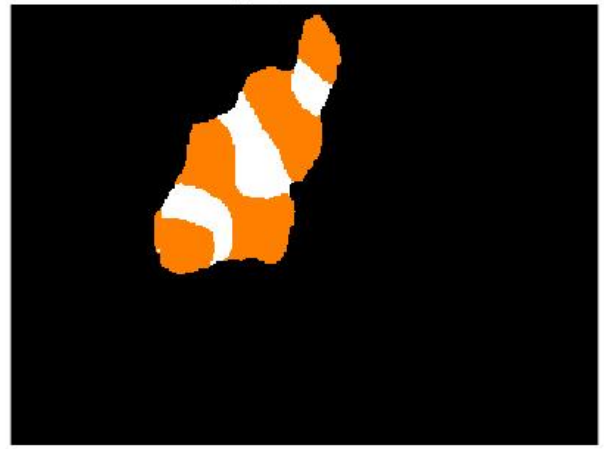


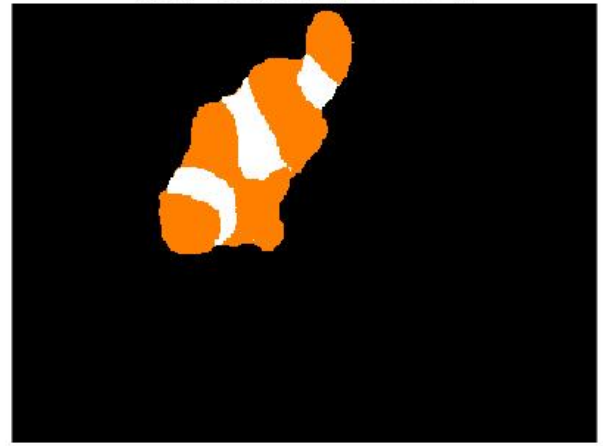
Figure 4: 结果对比: 315.bmp

文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)

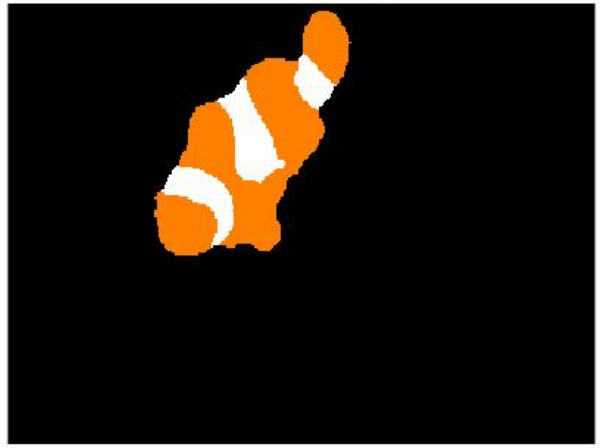
315.bmp 原图



方法1: 参数估计 (Gaussian)



方法2: Parzen窗



方法3: k-NN

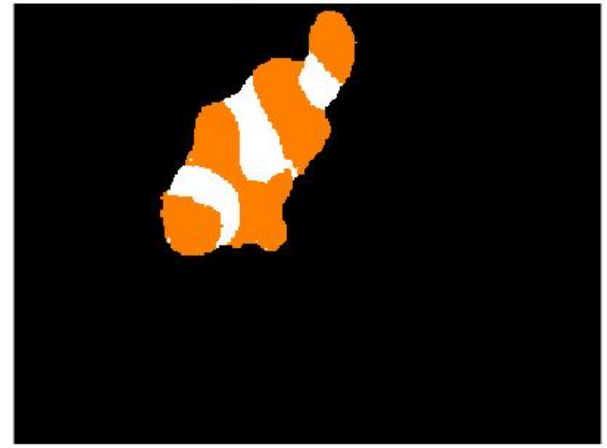


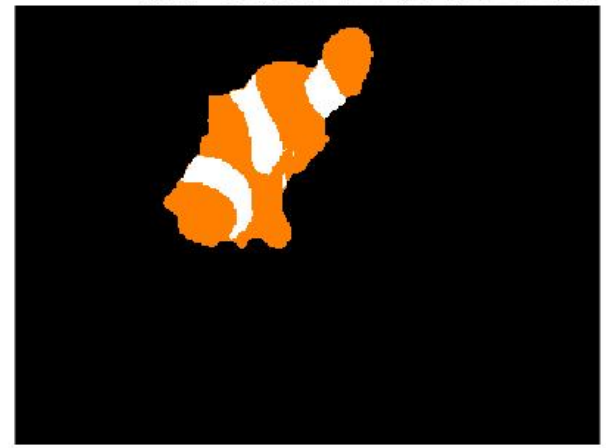
Figure 5: 结果对比: 317.bmp

文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)

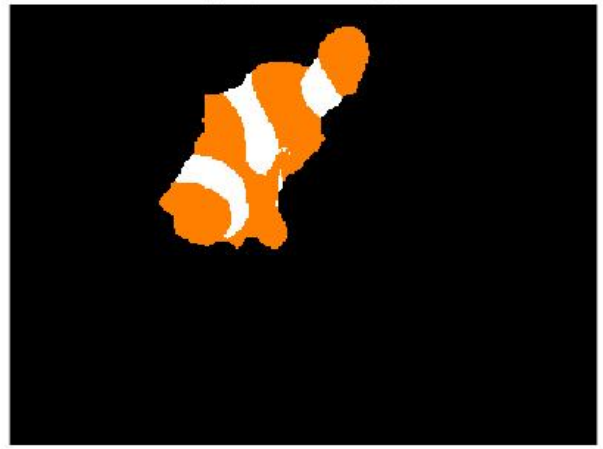
317.bmp 原图



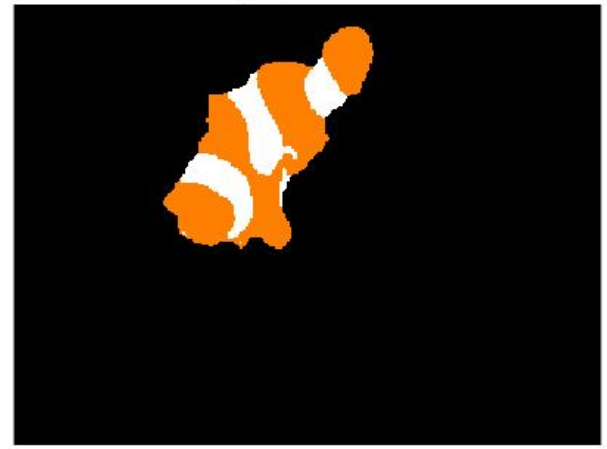
方法1: 参数估计 (Ga



方法2: Parzen窗



方法3: k-NN



算法性能横向对比

可视化方案：通过 `label2rgb_custom` 函数将逻辑标签映射回视觉色彩，直观评估分割效果，为算法性能排序提供可靠依据。

k-NN / Parzen

并列最优方案

表现：完整度最高，清晰识别橙/白色，无空洞且边界锐利。
原因：完美拟合真实分布，无单峰假设束缚。

3D Gaussian

性能表现次之

表现：可分割大致轮廓，但白色条纹识别差，边界模糊。
原因：单高斯模型被双峰分布欺骗，决策边界失效。

1D Gray

效果表现最差

表现：结果破碎，存在大量误判区域与空洞。
原因：丢失关键颜色信息，导致类别特征严重重叠。

实验有力证明：非参数密度估计方法（k-NN/Parzen）在复杂真实数据场景下，显著优于参数化的高斯模型。

感谢聆听

Q & A

欢迎各位专家、老师提问与交流